



Procesamiento del Lenguaje Natural

ISSN: 1135-5948

secretaria.sepln@ujaen.es

Sociedad Española para el  
Procesamiento del Lenguaje Natural  
España

Zafra Cremades, Saray; Gómez Sorian, José M.; Navarro-Colorado, Borja  
Diseño, compilación y anotación de un corpus para la detección de mensajes suicidas en  
redes sociales

Procesamiento del Lenguaje Natural, núm. 59, 2017, pp. 65-72

Sociedad Española para el Procesamiento del Lenguaje Natural  
Jaén, España

Disponible en: <http://www.redalyc.org/articulo.oa?id=515754427007>

- Cómo citar el artículo
- Número completo
- Más información del artículo
- Página de la revista en redalyc.org

redalyc.org

Sistema de Información Científica

Red de Revistas Científicas de América Latina, el Caribe, España y Portugal

Proyecto académico sin fines de lucro, desarrollado bajo la iniciativa de acceso abierto

# Diseño, compilación y anotación de un corpus para la detección de mensajes suicidas en redes sociales

## *Design, compilation and annotation of a corpus for the detection of suicide messages in social networks*

Saray Zafra Cremades, José M. Gómez Soriano, Borja Navarro-Colorado

Departamento de Lenguajes y Sistemas Informáticos (DLSI), Escuela Politécnica Superior IV  
Universidad de Alicante, E-03080 – Alicante  
{saray.zafra, jmgomez}@ua.es y borja@dlsi.ua.es

**Resumen:** Con el fin de desarrollar un sistema de prevención del suicidio en la red, se ha compilado y anotado un corpus piloto de mensajes de ideación suicida extraídos de las redes sociales. Los textos se han obtenido tanto de la Web como de la *Deep Web*, y se han seleccionado textos escritos tanto en español como en inglés. Para caracterizar semánticamente cada mensaje, éstos han sido anotados según su relación con el fenómeno suicida (pro-suicida, instigador, anti-suicidio, etc.). El proceso de compilación del corpus asegura la representatividad de los textos y la anotación consistente entre anotaciones.

**Palabras clave:** Corpus anotado, aprendizaje automático, prevención de suicidio, redes sociales

**Abstract:** In order to develop suicide prevention systems in the network, a pilot corpus of suicide thoughts was compiled and annotated. It was extracted from social networks. Texts has been obtained both from the Web and Deep Web. The selected written texts are in Spanish and English. Therefore, to characterize semantically each message, these have been annotated according to suicide relationship. The corpus compilation process ensures the representativeness of the texts and the consistent annotation between annotations.

**Keywords:** Annotated corpus, machine learning, suicide prevention, social networks

## 1 Introducción

La elección de quitarse la vida provoca más de 800.000 muertes al año y obedece a múltiples causas (Wasserman et al., 2004; Berk, 2006; De la Torre, 2013). La población más vulnerable son los jóvenes (Kessler et al., 1988; Mercy et al., 2001; Gould, Shaffer, y Kleinman, 1988), para los que el suicidio supone la segunda causa de muerte (WHO, 2014). Siendo éste el sector de población más activo en las redes sociales (INE, 2016), éstas constituyen un entorno ideal para compartir mensajes suicidas (Mok et al., 2016), lo que supone un gran peligro al producirse el efecto *Werther* o contagio: suicidios por imitación (Álvarez Torres, 2012).

Las Tecnologías del Lenguaje Humano (también conocidas como *TLH*) pueden ayudar la identificación temprana de signos de advertencia de suicidio por su capacidad para analizar y procesar grandes cantidades de

texto. Tareas como recuperación de información (Salton y McGill, 1986), clasificación de textos (Sebastiani, 2002), extracción de información (Cowie y Lehnert, 1996) o análisis de sentimientos (Pang y Lee, 2008) pueden ser recursos útiles para la detección de mensajes suicidas en las redes sociales.

Para ello, es necesario contar con un corpus anotado sobre mensajes relacionados con ideaciones suicidas con el fin de que se produzca un correcto desarrollo y evaluación de este tipo de herramientas. Con este objetivo, en el presente trabajo se describe el proceso de creación, anotación y evaluación de un corpus de mensajes suicidas extraídos tanto de redes sociales como de la *Deep Web*. A diferencia de corpus anteriores, los textos de este corpus proceden de ambientes no controlados. Los textos han sido anotados según la relación del mensaje con el suicidio (pro-suicida, instigador, irónico,...).

Este artículo se estructura en las siguientes secciones: tras una revisión del estado de la cuestión (Sección 2), se expone la metodología empleada para la creación del corpus, desde la compilación de los textos hasta el modelo de anotación (Sección 3). En la Sección 4 se muestran los resultados de la evaluación de la consistencia de la anotación. El trabajo finaliza con las conclusiones y los trabajos futuros (Sección 5).

## 2 Estado de la cuestión

En Psicología existen multitud de instrumentos para la detección de una depresión que pueda derivar en una conducta suicida, como pueden ser el *inventario de Depresión Rasgo-Estado* y el *inventario de Depresión* de Beck (1979). Éstos, sin embargo, no pueden ser extrapolados a la detección del fenómeno suicida a través de las redes sociales porque se basan en una serie de cuestionarios que no podemos aplicar a los usuarios anónimos de Internet.

En general, los corpus relacionados con el suicidio han centrado su atención en las notas suicidas escritas y la identificación y análisis de sus características más destacadas.

El primero de todos fue el corpus de notas genuinas (*GSN*) (Shneidman y Farberow, 1956), creado para identificar las características textuales propias de las notas de suicidio. Para ello, empleó una muestra de 66 notas suicidas de las cuales la mitad eran genuinas y la otra mitad simuladas. Este corpus ha sido empleado por muchos otros investigadores (Osgood y Walker, 1959; Gleser, Gottschalk, y Springer, 1961; Edelman y Renshaw, 1982).

Pestian desarrolló un amplio corpus de notas suicidas anonimizadas (Pestian et al., 2012) basado en la detección de la ideación suicida. Con una muestra de 1319 notas suicidas escritas entre 1950 y 2011 de las cuales se conservaron los errores gramaticales. Este corpus fue analizado con *Máquinas de Soporte Vectorial* (*Support Vector Machines, SVM*) para conseguir clasificar a los sujetos como: (i) suicidas, (ii) enfermos mentales y (iii) grupo de control (Pestian et al., 2016). Estas, también han sido empleadas en el ámbito del aprendizaje automático para clasificar la polaridad de aquellos textos en castellano compilados de redes sociales (Martínez Cámara et al., 2011; Martínez Cámara et al., 2013). Estas técnicas o el análisis de registros clínicos también han sido utilizados

por otros investigadores de *TLH* (Guan et al., 2015; Kessler et al., 2016; Amini et al., 2016; Iliou et al., 2016) para análisis generales de trastornos mentales, si bien éstos no tienen por qué estar relacionados directamente con el suicidio.

En 2014, Schwartz (2014) presenta un corpus compuesto por mensajes de redes sociales (mensajes de Facebook) de más de 28.749 usuarios. Este corpus se orienta principalmente en la detección de los cambios que se producen en la escritura de las personas con depresión diagnosticada.

(Nguyen et al., 2016) unen las notas de suicidio que forman parte del corpus *GSN* y los mensajes depositados en el sitio web *Experience Project*<sup>1</sup>. Este corpus, anotado por el propio autor, no indica ninguna valoración de su calidad así como tampoco indica ni el proceso de anotación ni la metodología recomendada. El entorno era controlado: se sabía que las notas suicidas procedían de suicidas reales y que los textos extraídos de la web eran sobre el tópico del suicidio en concreto.

Un poco alejado del tópico del suicidio encontramos el corpus de Mowery (2016), basado en la detección automática del trastorno depresivo mayor mediante el contenido escrito en Twitter. Para ello, obtienen una muestra de 900 tweets y emplean un proceso de anotación con 3 anotadores. El objetivo es clasificar cada tweet dentro de las categorías de salud mental establecidas en el *5th Diagnostic and Statidistic Manual of Mental Disorders* (DSM V). Este trabajo tiene dos principales problemas: solo tiene en cuenta que el trastorno depresivo mayor como factor de riesgo del fenómeno suicida y que solo se centra en Twitter.

Varios investigadores han experimentado con análisis de sentimientos basados en lexicones para la detección de blogs de suicidio (Huang, Goh, y Liew, 2007). Hasta donde conocemos, (Pestian et al., 2010) fue el primero en experimentar con aprendizaje y clasificación automática de notas de suicidio. Basándose en el corpus *GSN*, Pestian demostró que se podía discriminar automáticamente las notas falsas de las auténticas con mejor precisión que los profesionales de salud mental. Más tarde, Pennebaker (2011) usó la frecuencia de elementos verbales que expresaban cierta emoción o sentimiento en la narra-

<sup>1</sup><http://www.experienceproject.com/>

tiva de los pacientes para evidenciar que estas técnicas podían ser aplicadas para monitorizar los cambios emocionales descritos por los mismos.

El corpus presentado en este trabajo está formado por textos y mensajes procedentes de diferentes redes sociales, y se ha completado con textos de la *Deep Web*. En este sentido, es un corpus más representativo del mensaje suicida por ser, primero, textos creados en un entorno no controlado (son los propios mensajes de usuarios) y, segundo, por incluir muestras de diferentes fuentes digitales. El corpus, además, incluye mensajes en dos idiomas: español e inglés. Por último, como se expondrá en la siguiente sección, los mensajes han sido anotados según su relación con el fenómeno del suicidio.

### 3 Metodología de creación del corpus

El corpus<sup>2</sup> está formado por 97 textos escritos en diferentes redes sociales tanto en inglés como en español. El tamaño final es de 7968 *tokens* y 2225 *types*, si incluimos los términos *stopwords*, y de 2855 *tokens* y de 1808 *types* si los excluimos. Aproximadamente el 33% son textos mayoritariamente en español mientras que el 67% son en inglés.

En la Figura 1 se puede apreciar cuántos *tokens* distintos (*types*) aparecen por su frecuencia de aparición sin tener en cuenta los *stopwords*. En el corpus aparece 1337 *types* que sólo se mencionan una vez; 268 *types* que aparecen dos veces, 84 *types* que aparecen en 3 ocasiones y así hasta los *types* que aparecen en más de 8 veces en el corpus solo se repiten 4 o menos veces. Por supuesto, estos datos se realizan sin lematizar ni realizar ningún otro proceso de reducción léxica.

#### 3.1 Búsqueda y selección de textos

Con el fin de obtener un corpus lo más representativo posible del tema tratado (Bowker, 2002) (mensajes suicidas en redes sociales), la búsqueda y selección de los textos se basó en el siguiente proceso:

1. Revisión bibliográfica sobre en que foros y páginas de redes sociales tanto de la *Deep Web* como de la *Surface Web* pueden tratarse temáticas suicidas.



Figura 1: Número de types por ocurrencias en escala logarítmica

2. Búsqueda en dichos foros y páginas de redes sociales con el objetivo de obtener un corpus lo más balanceado posible (con el número suficiente de muestras de ideación suicida y muestras indefinidas). Las indefinidas son las que no han podido ser clasificadas como suicidas (ver Sección 3.2).
3. Tras el proceso anterior, se obtuvieron los hashtags más frecuentes, los usuarios más activos y las expresiones más comunes como “no aguanto más”, lo que llevo a la creación de una lista de palabras frecuentes relacionadas con el suicidio y emociones profundas, como *Suicidio*, *muerte*, *pro suicida*, *perdón*, *olvido*, *depresión*, *insatisfacción* y *ayuda*. Estas palabras se utilizan como palabras semilla o términos clave para buscar en redes sociales (*Deep Web* y *Surface Web*) más mensajes y textos relacionados con el suicidio.
4. A partir de los textos encontrados, creación de una nueva lista de palabras semilla que complete la lista inicial. En ésta se incluyen palabras como *hastío vital*, *angustia*, *soledad*, *impotencia*, etc. Nueva búsqueda de textos con esta lista ampliada de términos clave.
5. Del conjunto de textos obtenidos, se seleccionaron aquéllos más destacados, re-tuiteados, respondidos y con más *likes*, considerando por tanto éstos como los más representativos del hecho suicida. Por la escasez de notas suicidas en las redes sociales, aquellas encontradas fueron directamente seleccionadas, sobre todo si

<sup>2</sup><https://github.com/plataformalifeua>

tenía respuestas.

Para la búsqueda en la *Deep Web* se utilizó el navegador *TOR*<sup>3</sup>.

A diferencia de otros corpus y recursos sobre el suicidio, todos los textos de nuestro corpus son auténticos, es decir, son fruto de la libre expresión del autor, todos tienen relación con el tema del suicidio y han sido creados en el momento que el autor los escribió. No se han incluido, por tanto, notas de suicidio creadas *ad hoc* para el corpus ni textos artificiales creados después de la manifestación de la ideación suicida. En nuestro corpus es el usuario el que escoge un entorno concreto como son las redes sociales de la *Deep Web* para la expresión de unas ideas muy enfocadas en el fenómeno del suicidio, lo que le otorga una mayor libertad para expresar las mismas de modo no condicionado. En este sentido, los textos del corpus son muy representativo de los usos lingüísticos suicidas.

### 3.2 Anotación

Cada texto del corpus está marcado con la siguiente información:

- Red social de procedencia: *Facebook*, *Twitter*, *Blogspot*, *Reddit*, *Pinterest*.
- Identificador del usuario o *Nickname* del creador del mensaje, o en su defecto nombre de la página pública.
- Fuente: *Deep Web* o *Surface Web*.
- Palabras relevantes.
- Idioma: español o inglés.
- Tipo de Mensaje (ver luego).
- Observaciones: Fueron necesarias en algunos textos en los que tuvimos que contactar con el usuario por su gravedad o en casos con perfiles muy concretos y que creímos que podían ayudar al anotador.

El idioma fue anotado automáticamente por *GATE Developer 8.2* y posteriormente se realizó una supervisión humana detectando una tasa de error del 1 %.

El tipo de mensaje se refiere a la relación del texto con el hecho suicida. Para ello se han definido las siguientes categorías:

1. *Auto-Pro-Suicida*: Conductas negativas y a favor de la expresión de ideaciones

suicidas, deseo de morir, comportamientos auto-lesivos, sensación de hastío o manifestación indirecta de estados depresivos. Por ejemplo:

- (1) “La vida es un vacío constante, lleno de soledad y angustia”.

“Hola, te molesto? Estoy llorando, nadie me habla. Estoy llorando, nadie me entiende. No quiero molestar a mis amigos con mi problema. Me encierro en el baño a llorar. Me tapo la cara con las manos, me miro al espejo y lloro más por estar llorando, por una idiotez”.

2. *Auto-No-Pro-Suicida*: Conductas positivas y en total desacuerdo con el suicidio, deseo de morir, comportamientos auto-lesivos o de apoyo a otros usuarios mediante testimonios acerca de la superación de ideas suicidas. Por ejemplo:

- (2) “Yo también entiendo por lo que estás pasando, pero de todo se sale”.

“Mi felicidad solo depende de una persona, y esa persona soy yo.”

3. *Citas*: Citas textuales (reales o apócrifas) relacionadas con el suicidio o, en general, la muerte. Por ejemplo:

- (3) “Lo que no te mata te hace más fuerte. Friedrich Nietzsche.”

“Aún tengo las palabras de mi suegra resonando en mi cabeza: “Aprovechad ahora que podéis”, “Ya no os vais a ver tan a menudo como antes”, “No vas a poder venir todos los fines de semana.”

4. *Depresión*: Expresión directa del diagnóstico acerca de un estado o trastorno depresivo, como por ejemplo:

- (4) “I have been diagnosed with depression 6 months ago”.

5. *Irónico*: Textos que expresan lo contrario de lo que el sentido literal manifiesta, como por ejemplo:

- (5) “It’s like choosing soup over the salad. *Life is cool*, ;) ;)”

“Si Si, Quédate con el borracho, verás que bien te va...”.

6. *Instigador*: Textos que animan a otros usuarios a cometer actos suicidas. Por ejemplo:

<sup>3</sup><https://www.torproject.org/download/download-easy.html.en>

- (6) “Suicide is a fast solution. Don’t hesitate”.
7. *Misticidad*: Manifestación indirecta de la idea de morir mediante cuestiones religiosas o místicas. Por ejemplo:
- (7) “Soy inmortal, la muerte me huye y Dios me condena por mi insolencia. De nada sirve tenerlo todo si la persona que mas amas no está a tu lado”.
8. *Tristeza/Melancolía*: (i) expresión directa de la palabra *melancolía*, (ii) de ideas relacionadas con la tristeza y (iii) composiciones poéticas propias, como por ejemplo:
- (8) “Tengo una soledad tan concurrida, tan llena de rostros de vos”.
- “He crecido escondido tras el cadáver de tus noches, hambriento como un recuerdo, herido como una bala. Soñando la llegada de mil futuros mejores, te he mencionado, y en vano he repetido en voz muy alta tu nombre”.
9. *Indefinido*: Textos incardinables en ninguna de las categorías anteriores debido a que o bien no es posible asignar a una de las categorías anteriores puesto que nos falta información contextual, o que, simplemente, no expresan ninguna relación con el suicidio. Por ejemplo:
- (9) “Me compré un perro y me apunté al gimnasio. Eso ayuda.”
- “Quédate con quien te escriba un mensaje borracho de madrugada, es quien piensa en ti cuando ya no puede pensar”

En la Tabla 1 se muestran las nueve categorías y la cantidad de mensajes asignados a cada una. Algunos textos han sido clasificados en dos categorías.

Del análisis extraído de la revisión bibliográfica no se ha podido establecer un modelo teórico concreto para la codificación de las categorías puesto que no hay una aproximación tan enfocada a la detección de la ideación suicida en las redes sociales. En vez de ello, hemos propuesto nuestra propia categorización a partir de la experiencia derivada de los textos extraídos y del objetivo final del proyecto, que es la detección de este tipo de mensajes con el fin último de evitar el suicidio.

Categoría	#
Auto-Pro-Suicida	22
Auto-No-Pro-Suicida	10
Citas	2
Depresión	9
Ironía	3
Instigador	1
Misticidad	1
Tristeza/Melancolía	11
Indefinido	38

Tabla 1: Categorías del corpus y el número de muestras anotadas con cada categoría

Como podemos observar en la Tabla 1 existe una gran divergencia en el número de muestras para cada categoría, siendo la categoría *Indefinido* la más popular seguida de las *Auto-Pro-Suicida* y *Auto-No-Pro-Suicida*. Esto ha sido un fenómeno que refleja la realidad de los textos obtenidos y del proceso sistemático utilizado. Esto muestra una necesidad de aumentar este corpus preliminar para obtener más muestras de ciertas categorías. Con un corpus más amplio podríamos llegar a obtener muestras más representativas de cada categoría. También se puede observar que, pese a que las muestras categorizadas como *Indefinido* son un 39,2 % del total, esto permitirá a un sistema de aprendizaje automático tener suficientes muestras tanto positivas como negativas para aprender, aunque el corpus no esté del todo balanceado. Si agrupamos entre muestras que podríamos relacionar con el suicidio (*Auto-Pro-Suicida*, *Depresión*, *Ironía*, *Instigador*, *Tristeza/Melancolía*) y que queremos que nuestro sistema distinga de los mensajes no preocupantes (*Auto-No-Pro-Suicida*, *Citas*, *Misticidad* e *Indefinido*) vemos como el corpus está prácticamente balanceado, puesto que el primer grupo representaría el 47,4 % mientras que el segundo un 52,6 %.

### 3.3 Proceso de anotación

A partir de esta clasificación semántica de los tipos de mensajes suicidas se creó una pequeña guía de anotación como documento base del proceso de anotación.

Debido a la falta de recursos, el corpus ha sido anotado por un solo anotador. Sin embargo, para asegurar la consistencia de la anotación, el corpus se ha anotado entero dos veces en distintos periodos de tiempo, con una diferencia de ocho meses entre la primera y la segunda anotación. De esta manera se

puede observar si la categoría asignada a cada texto es la misma en uno y otro momento.

La anotación se realizó con *GATE Developer 8.2* (Cunningham et al., 2017), para lo que se creó un *plugin* con las diferentes categorías definidas y el resto de atributos a anotar.

#### 4 Evaluación de la anotación

Para comprobar la consistencia de la anotación se ha calculado el acuerdo entre las dos anotaciones realizadas por la misma persona pero en distintos periodos de tiempo (*Inter Annotators Agreement*). Para medir este acuerdo hemos empleado dos coeficientes kappa: el original de Cohen (1960) y el de (Bonnyman et al., 2012). Este último es útil siempre y cuando nos encontremos ante la misma situación o fenómeno y que el anotador sea el mismo (Mchugh, 2012), de tal manera que permite medir su propio nivel de acuerdo pasado un tiempo concreto. Por ello consideramos que es aplicable a nuestro caso, en el que la anotación se realizó por la misma persona en dos periodos de tiempo diferentes (junio 2016 y marzo 2017). La Tabla 2 muestra los resultados obtenidos.

Propiedad	Cohen	Bonnyman
Idioma	99 %	.97
Tipo de texto	100 %	1

Tabla 2: Intra-rater reliability

Según Mchugh (2012), los valores de Bonnyman et al. (2012) pueden interpretarse del siguiente modo:

1. *Sin Acuerdo*: Igual o menor de 0.
2. *Acuerdo Bajo*: 0.01-0.20.
3. *Acuerdo Justo*: 0.21-0.40.
4. *Acuerdo Moderado* : 0.41-0.60.
5. *Acuerdo Sustancial* : 0.61-0.80.
6. *Acuerdo casi perfecto* : 0.81-1.00.

Tal y como podemos observar en la Tabla 2, los resultados indican que la anotación es consistente.

Respecto al idioma, el hecho de que *GATE* identificara el idioma de modo automático derivó en la necesidad de establecer en la segunda fase de anotación un procedimiento manual para anotar el idioma, puesto que lo que nos interesa es el idioma principal del mensaje, no el primero en aparecer en un texto.

#### 5 Conclusiones y trabajo futuro

En este trabajo hemos presentado un corpus anotado para la detección del suicidio compilado desde las redes sociales de la Web y Deep Web tanto en inglés como en español. El mismo ha seguido un proceso de compilación y anotación concretos en aras de que la representatividad no se viera mermada.

Los resultados expuestos constituyen un punto de partida para futuros trabajos e investigaciones relacionadas con el suicidio. Estamos ante un problema complejo y multifactorial que requiere de un enfoque integral tanto para su detección como para la intervención por parte de todos los profesionales que trabajan en el campo de prevención de suicidios y en redes sociales.

Las redes sociales, especialmente en jóvenes, constituyen un nuevo modo de comunicación entre iguales que comparten la misma visión negativa de la vida, lo que genera la posibilidad de encontrarnos ante casos en los que el suicidio sea fruto de la imitación (Álvarez Torres, 2012).

Con un corpus de gran entidad y calidad, podría llegar a generarse una plataforma que, en función del nivel de alerta establecido para un mensaje procedente de una red social, derivara a los servicios de salud correspondientes. El corpus que forma parte de este piloto, ha sido el primer paso para establecer qué es lo que no ha funcionado a lo largo del proceso de anotación, que categorías eran las más adecuadas, en qué redes sociales es posible encontrar más información y sobre todo, cuál es el riesgo de intervención o no mediante la recolección de textos de un mismo usuario.

Una vez evaluados y confirmados los aspectos metodológicos usados en el presente trabajo, queremos seguir ampliando este corpus sobre el fenómeno suicida para que pueda ser validado, también, en su uso por sistemas de aprendizaje automático para que éstos sean capaces de detectar, con suficiente precisión y cobertura, la depresión y la ideación suicida y así solventar estos graves problemas sociales, evitando (en la medida de lo posible) muertes innecesarias.

#### Agradecimientos

Este trabajo ha sido parcialmente financiado por el proyecto nacional TIN2015-65100-R y por las Ayudas Fundación BBVA a equipos de investigación científica para el proyecto *Análisis de Sentimientos Aplicado a la*

*Prevención del Suicidio en las Redes Sociales* (ASAP). Agradecimientos especiales a Isabel Moreno Agulló y Beatriz Botella Gil.

## Bibliografía

- Álvarez Torres, S. M. 2012. Efecto Werther: Una propuesta de intervención en la facultad de Ciencias Sociales y de la Comunicación (UPV/EHU). *Norte de Salud Mental*, (42):48–55.
- Amini, P., H. Ahmadiania, J. Poorolajal, y M. Amiri Moqaddasi. 2016. Evaluating the High Risk Groups for Suicide: A Comparison of Logistic Regression, Support Vector Machine, Decision Tree and Artificial Neural Network. *Iran J Public Health*, 45(9):1179–1187.
- Berk, M. y Dodd, H. S. 2006. The effect of macroeconomic variables on suicide. *Psychol Med*, 36(2):181–189.
- Bonnyman, A. M., C. E. Webber, P. W. Stratford, y N. J. MacIntyre. 2012. Intrarater Reliability of Dual-Energy X-Ray Absorptiometry-Based Measures of Vertebral Height in Postmenopausal Women. *Journal of Clinical Densitometry*, 15(4):405–412, oct.
- Bowker, Lynne y Pearson, J. 2002. Working with Specialized Language: A Practical Guide to Using Corpora. *Computer-Aided Translation Technology*.
- Cohen, J. 1960. A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, 20(1):37–46, apr.
- Cowie, J. y W. Lehnert. 1996. Information extraction. *Communications of the ACM*, 39(1):80–91, jan.
- Cunningham, H., D. Maynard, K. Bontcheva, V. Tablan, N. Aswani, I. Roberts, G. Gorrell, A. Funk, A. Roberts, D. Damljano-vic, T. Heitz, M. A. Greenwood, H. Saggion, J. Petrak, Y. Li, W. Peters, Deczynski, y Leon. 2017. Developing Language Processing Components with GATE Version 8 (a User Guide).
- De la Torre, M. 2013. Protocolo para la detección y atención inicial de la ideación suicida. *Universidad Autónoma de Madrid*, páginas 1–36.
- Edelman, A. M. y S. L. Renshaw. 1982. Genuine versus simulated suicide notes: an issue revisited through discourse analysis. *Suicide & life-threatening behavior*, 12(2):103–113, jan.
- Gleser, G. C., L. A. Gottschalk, y K. J. Springer. 1961. An anxiety scale applicable to verbal samples. *Archives of general psychiatry*, 5:593–605, dec.
- Gould, M. S., D. Shaffer, y M. Kleinman. 1988. The Impact of Suicide in Television Movies: Replication and Commentary. *Suicide and Life-Threatening Behavior*, 18(1):90–99, sep.
- Guan, L., B. Hao, Q. Cheng, P. S. Yip, y T. Zhu. 2015. Identifying Chinese Microblog Users With High Suicide Probability Using Internet-Based Profile and Linguistic Features: Classification Model. *JMIR mental health*, 2(2):e17, may.
- Huang, Y.-P., T. Goh, y C. L. Liew. 2007. Hunting Suicide Notes in Web 2.0 - Preliminary Findings. En *Ninth IEEE International Symposium on Multimedia Workshops (ISMW 2007)*, páginas 517–521. IEEE, dec.
- Iliou, T., G. Konstantopoulou, M. Ntekouli, D. Lymberopoulos, K. Assimakopoulos, D. Galiatsatos, y G. Anastassopoulos. 2016. Machine Learning Preprocessing Method for Suicide Prediction. Springer, Cham, páginas 53–60.
- INE. 2016. Encuesta sobre Equipamiento y Uso de Tecnologías de Información y Comunicación en los Hogares. Año 2016. página 1.
- Kessler, R. C., G. Downey, J. R. Milavsky, y H. Stipp. 1988. Clustering of teenage suicides after television news stories about suicides: A reconsideration. *American Journal of Psychiatry*, 145(11):1379–1383, sep.
- Kessler, R. C., H. M. van Loo, K. J. Wardenaar, R. M. Bossarte, L. A. Brenner, T. Cai, D. D. Ebert, I. Hwang, J. Li, P. de Jonge, A. A. Nierenberg, M. V. Petukhova, A. J. Rosellini, N. A. Sampson, R. A. Schoevers, M. A. Wilcox, y A. M. Zaslavsky. 2016. Testing a machine-learning algorithm to predict the persistence and severity of major depressive disorder from baseline self-reports. *Molecular Psychiatry*, (October 2015):1–6.



- Martínez Cámara, E., M. Á. García Cumbreas, M. T. Martín Valdivia, y L. A. Ureña López. 2013. SINAI en TASS 2012. *Procesamiento del Lenguaje Natural*, 50:53–60.
- Martínez Cámara, E., M. T. Martín Valdivia, J. M. Perea Ortega, y L. A. Ureña López. 2011. Técnicas de clasificación de opiniones aplicadas a un corpus en español. *Procesamiento del Lenguaje Natural*, 47:163–170.
- McHugh, M. L. 2012. Lessons in biostatistics Interrater reliability : the kappa statistic. páginas 276–282.
- Mercy, J. A., M. J. Kresnow, P. W. O’Carroll, R. K. Lee, K. E. Powell, L. B. Potter, A. C. Swann, R. F. Frankowski, y T. L. Bayer. 2001. Is suicide contagious? A study of the relation between exposure to the suicidal behavior of others and nearly lethal suicide attempts. *American Journal of Epidemiology*, 154(2):120–127, jul.
- Mok, K., A. M. Ross, A. F. Jorm, y J. Pirkis. 2016. An Analysis of the Content and Availability of Information on Suicide Methods Online. *Journal of Consumer Health on the Internet*, 20(1-2):41–51, apr.
- Mowery, D., H. A. Smith, T. Cheney, C. Bryan, y M. Conway. 2016. Identifying Depression-Related Tweets from Twitter for Public Health Monitoring. *Online Journal of Public Health Informatics*, 8(1), mar.
- Nguyen, T., T. Tran, S. Gopakumar, D. Phung, y S. Venkatesh. 2016. An evaluation of randomized machine learning methods for redundant data: Predicting short and medium-term suicide risk from administrative records and risk assessments. páginas 1–29.
- Osgood, C. E. y E. G. Walker. 1959. Motivation and language behavior: a content analysis of suicide notes. *Journal of abnormal psychology*, 59(1):58–67, jul.
- Pang, B. y L. Lee. 2008. Opinion Mining and Sentiment Analysis. *Foundations and Trends® in Information Retrieval*, 2(1-2):1–135, jan.
- Pennebaker, J. W. y C. K. Chung. 2011. Expressive Writing, Emotional Upheavals, and Health. En Howard S. Friedman, editor, *Expressive Writing, Emotional Upheavals, and Health*. Oxford University Press, capítulo 18, página 936.
- Pestian, J., H. Nasrallah, Matykiewicz, A. Bennett, y A. Leenaars. 2010. Suicide Note Classification Using Natural Language Processing. *Biomed Inform Insights*, 3:19–28.
- Pestian, J. P., P. Matykiewicz, M. Linn-Gust, B. South, O. Uzuner, J. Wiebe, K. B. Cohen, J. Hurdle, y C. Brew. 2012. Sentiment Analysis of Suicide Notes: A Shared Task. *Biomedical informatics insights*, 5(Suppl 1):3–16, jan.
- Pestian, J. P., M. Sorter, B. Connolly, K. B. Cohen, J. T. Gee, L.-p. Morency, y S. Scherer. 2016. A Machine Learning Approach to Identifying the Thought Markers of Suicidal Subjects : A Prospective Multicenter Trial. *The American Association of Suicidology*, páginas 1–10.
- Salton, G. y M. J. McGill. 1986. *Introduction to Modern Information Retrieval*. McGraw-Hill, Inc., oct.
- Schwartz, H. A., J. Eichstaedt, M. L. Kern, G. Park, M. Sap, D. Stillwell, M. Kosinski, y L. Ungar. 2014. Towards Assessing Changes in Degree of Depression through Facebook. En *Proceedings of the Workshop on Computational Linguistics and Clinical Psychology: From Linguistic Signal to Clinical Reality*, páginas 118–125, Baltimore. Association for Computational Linguistics.
- Sebastiani, F. 2002. Machine learning in automated text categorization. *ACM Computing Surveys*, 34(1):1–47, mar.
- Shneidman, E. S. y N. L. Farberow. 1956. Clues to suicide. *Public health reports*, 71(2):109–14, feb.
- Wasserman, D., E. Mittendorfer Rutz, W. Rutz, y A. Schmidtke. 2004. Suicide Prevention In Europe. Informe técnico, National and Stockholm County Council’s Centre for Suicide Research and Prevention of Mental Ill-Health.
- WHO. 2014. Preventing suicide: A global imperative. Informe técnico, World Health Organization.